

Projekt 2: Podsumowania lingwistyczne relacyjnych baz danych

Załącznik zawiera szczegółowy opis utworzonych zmiennych lingwistycznych.

1 Zmienne lingwistyczne (atrybuty/własności obiektów)

Przyjmujemy następujące oznaczenia:

- N_w - liczba słów w treści artykułu
- N_u - liczba unikalnych słów
- N_t - liczba słów w tytule
- N_p - liczba słów uznanych za pozytywne
- N_n - liczba słów uznanych za negatywne
- N_h - liczba linków w artykule

Zdefiniowano trapezową funkcję przynależności [?] τ :

$$\tau(x, a, b, c, d) = \begin{cases} 0 & \text{dla } x \leq a \\ \frac{x-a}{b-a} & \text{dla } a < x < b \\ 1 & \text{dla } b \leq x \leq c \\ \frac{d-x}{d-c} & \text{dla } c < x < d \\ 0 & \text{dla } x \geq d \end{cases} \quad (1)$$

gdzie:


- $\tau(x)$ - trapezowa funkcja przynależności ($\tau(x) \in [0, 1]$)
- a, b, c, d - kolejne od lewej wierzchołki trapezu: $a < b < c < d$

1.1 Atrakcyjność wizualna

$$a_r = N_i \quad (2)$$

gdzie:

- a_r - bogactwo wizualne artykułu. $a_r \in [0, 128]$
- N_i - liczba zdjęć w artykule



Rysunek 1: Funkcje przynależności trapezowe dla zmiennej a_r

Etykiety:

- Surowa

$$\mu_{niskie}(x) = \tau(x, -\infty, 0, 10, 14) \quad (3)$$

- Zbalansowana

$$\mu_{średnie}(x) = \tau(x, 12, 15, 20, 30) \quad (4)$$

- Atrakcyjna


$$\mu_{wysokie}(x) = \tau(x, 25, 45, 128, \infty) \quad (5)$$

1.2 Bogactwo źródeł

$$a_h = N_h \quad (6)$$

gdzie:

- w_n - Bogactwo źródeł. $a_h \in [0, 304]$
- N_h - liczba linków w artykule



Rysunek 2: Funkcje przynależności trapezowe dla zmiennej a_h

Etykiety:

- Ubogie

$$\mu_{niskie}(x) = \tau(x, -\infty, 0, 8, 12) \quad (7)$$

- Średnie

$$\mu_{średnie}(x) = \tau(x, 10, 14, 20, 25) \quad (8)$$

- Bogate


$$\mu_{wysokie}(x) = \tau(x, 23, 40, 304, \infty) \quad (9)$$

1.3 Unikalność słów artykułu

$$t_r = \frac{N_u}{N_w} \quad (10)$$

gdzie:

- t_r - współczynnik unikalnych słów. $t_r \in [0.11, 1]$



Rysunek 3: Funkcje przynależności trapezowe dla zmiennej t_r

Etykiety:

- Pospolity

$$\mu_{pospolity}(x) = \tau(x, -\infty, 0.11, 0.2, 0.35) \quad (11)$$

- Średni

$$\mu_{sredni}(x) = \tau(x, 0.3, 0.5, 0.65, 0.75) \quad (12)$$

- Unikalny


$$\mu_{unikalny}(x) = \tau(x, 0.6, 0.8, 1, +\infty) \quad (13)$$

1.4 Średnia długość słowa

$$w_l = \frac{\sum_{i=1}^{N_w} \text{len}(w_i)}{N_w} \quad (14)$$

gdzie:

- w_l - średnia długość słowa. $w_l \in [3.6, 8.04]$
- w_i - i-te słowo artykułu
- $\text{len}(x)$ - długość słowa x



Rysunek 4: Funkcje przynależności trapezowe dla zmiennej w_l

Etykiety:

- Mała

$$\mu_{mala}(x) = \tau(x, -\infty, 3.6, 4.4, 5) \quad (15)$$

- Średnia

$$\mu_{srednia}(x) = \tau(x, 4.1, 5.2, 6.1, 6.5) \quad (16)$$

- Duża


$$\mu_{duza}(x) = \tau(x, 6.3, 7.1, 8.04, +\infty) \quad (17)$$

1.5 Współczynnik subiektywności artykułu

$$a_s = \frac{\sum_{i=1}^{N_w} sub(w_i)}{N_w} \quad (18)$$

gdzie:

- a_s - współczynnik subiektywności artykułu. $a_s \in [0, 1]$
- w_i - i-te słowo artykułu
- $sub(x)$ - wartość subiektywności słowa x w skali 0-1, gdzie 1 to opinia, a 0 to fakt.



Rysunek 5: Funkcje przynależności trapezowe dla zmiennej a_s

Etykiety:

- Bardzo obiektywny

$$\mu_{bobjektywny}(x) = \tau(x, -\infty, 0, 0.15, 0.25) \quad (19)$$

- Obiektywny

$$\mu_{objektywny}(x) = \tau(x, 0.2, 0.35, 0.45, 0.55) \quad (20)$$

- Subiektywny

$$\mu_{subiektywny}(x) = \tau(x, 0.45, 0.55, 0.65, 0.8) \quad (21)$$

- Bardzo subiektywny


$$\mu_{bsubiektywny}(x) = \tau(x, 0.75, 0.85, 1, +\infty) \quad (22)$$

1.6 Współczynnik nacechowania emocjonalnego artykułu

$$a_e = \frac{\sum_{i=1}^{N_w} em(w_i)}{N_w} \quad (23)$$

gdzie:

- a_e - współczynnik nacechowania emocjonalnego. $a_e \in [-0.39, 0.73]$
- w_i - i-te słowo artykułu
- $em(x)$ - wartość nacechowania emocjonalnego słowa x w skali $[-1,1]$, gdzie -1 to tekst bardzo negatywny, a 1 to bardzo pozytywny.



Rysunek 6: Funkcje przynależności trapezowe dla zmiennej a_e

Etykiety:

- Bardzo negatywny

$$\mu_{bardzo\ negatywny}(x) = \tau(x, -\infty, -0.39, -0.25, -0.2) \quad (24)$$

- Negatywny

$$\mu_{negatywny}(x) = \tau(x, -0.25, -0.1, 0, 0.1) \quad (25)$$

- Neutralny

$$\mu_{neutralny}(x) = \tau(x, 0, 0.1, 0.25, 0.4) \quad (26)$$

- Pozytywny

$$\mu_{pozytywny}(x) = \tau(x, 0.3, 0.4, 0.55, 0.65) \quad (27)$$

- Bardzo pozytywny


$$\mu_{bardzo\ pozytywny}(x) = \tau(x, 0.55, 0.65, 0.73, +\infty) \quad (28)$$

1.7 Współczynnik subiektywności tytułu

$$t_s = \frac{\sum_{i=1}^{N_w} sub(w_i)}{N_t} \quad (29)$$

gdzie:

- t_s - współczynnik subiektywności artykułu. $t_s \in [0, 1]$
- w_i - i-te słowo artykułu
- $sub(x)$ - wartość subiektywności słowa x w skali 0-1, gdzie 1 to opinia, a 0 to fakt.



Rysunek 7: Funkcje przynależności trapezowe dla zmiennej t_s

Etykiety:

- Bardzo obiektywny

$$\mu_{bobjektywny}(x) = \tau(x, -\infty, 0, 0.15, 0.2) \quad (30)$$

- Obiektywny

$$\mu_{objektywny}(x) = \tau(x, 0.15, 0.25, 0.4, 0.6) \quad (31)$$

- Subiektywny

$$\mu_{subiektywny}(x) = \tau(x, 0.4, 0.6, 0.75, 0.85) \quad (32)$$

- Bardzo subiektywny


$$\mu_{bsubiektywny}(x) = \tau(x, 0.8, 0.85, 1, +\infty) \quad (33)$$

1.8 Współczynnik nacechowania emocjonalnego tytułu

$$t_e = \frac{\sum_{i=1}^{N_w} em(w_i)}{N_t} \quad (34)$$

gdzie:

- t_e - współczynnik nacechowania emocjonalnego tytułu. $t_e \in [-1, 1]$
- w_i - i-te słowo artykułu
- $em(x)$ - wartość nacechowania emocjonalnego słowa x w skali $[-1, 1]$, gdzie -1 to tekst bbardzo negatywny, a 1 to bardzo pozytywny.



Rysunek 8: Funkcje przynależności trapezowe dla zmiennej t_e

Etykiety:

- Negatywny

$$\mu_{negatywny}(x) = \tau(x, -\infty, -1, -0.6, 0.25) \quad (35)$$

- Neutralny

$$\mu_{neutralny}(x) = \tau(x, -0.5, -0.25, 0.25, 0.5) \quad (36)$$

- Pozytywny


$$\mu_{pozytywny}(x) = \tau(x, 0.25, 0.6, 1, +\infty) \quad (37)$$

1.9 Stosunek pozytywnych słów

$$p = \frac{N_p}{N_p + N_n} \quad (38)$$

gdzie:

- p - współczynnik pozytywnych słów. $p \in [0, 1]$



Rysunek 9: Funkcje przynależności trapezowe dla zmiennej p

Etykiety:

- Niski

$$\mu_{niski}(x) = \tau(x, -\infty, 0, 0.25, 0.4) \quad (39)$$

- Średni

$$\mu_{średni}(x) = \tau(x, 0.25, 0.4, 0.6, 0.75) \quad (40)$$

- Wysoki


$$\mu_{wysoki}(x) = \tau(x, 0.6, 0.75, 1, +\infty) \quad (41)$$

1.10 Popularność artykułu

$$s = N_s \quad (42)$$

gdzie:

- s - popularność artykułu $s \in [1, 843300]$
- N_s - liczba udostępnień artykułu



Rysunek 10: Funkcje przynależności trapezowe dla zmiennej s

Etykiety:

- Bardzo niszowy

$$\mu_{bniszowy}(x) = \tau(x, -\infty, 1, 15, 50) \quad (43)$$

- Niszowy

$$\mu_{niszowy}(x) = \tau(x, 20, 40, 100, 150) \quad (44)$$

- Średni

$$\mu_{sredni}(x) = \tau(x, 175, 1800, 5500, 7000) \quad (45)$$

- Popularny

$$\mu_{popularny}(x) = \tau(x, 6500, 15000, 25000, 55000) \quad (46)$$

- Bardzo popularny

$$\mu_{popularny}(x) = \tau(x, 50000, 100000, 843300, +\infty) \quad (47)$$